



Лекция 05

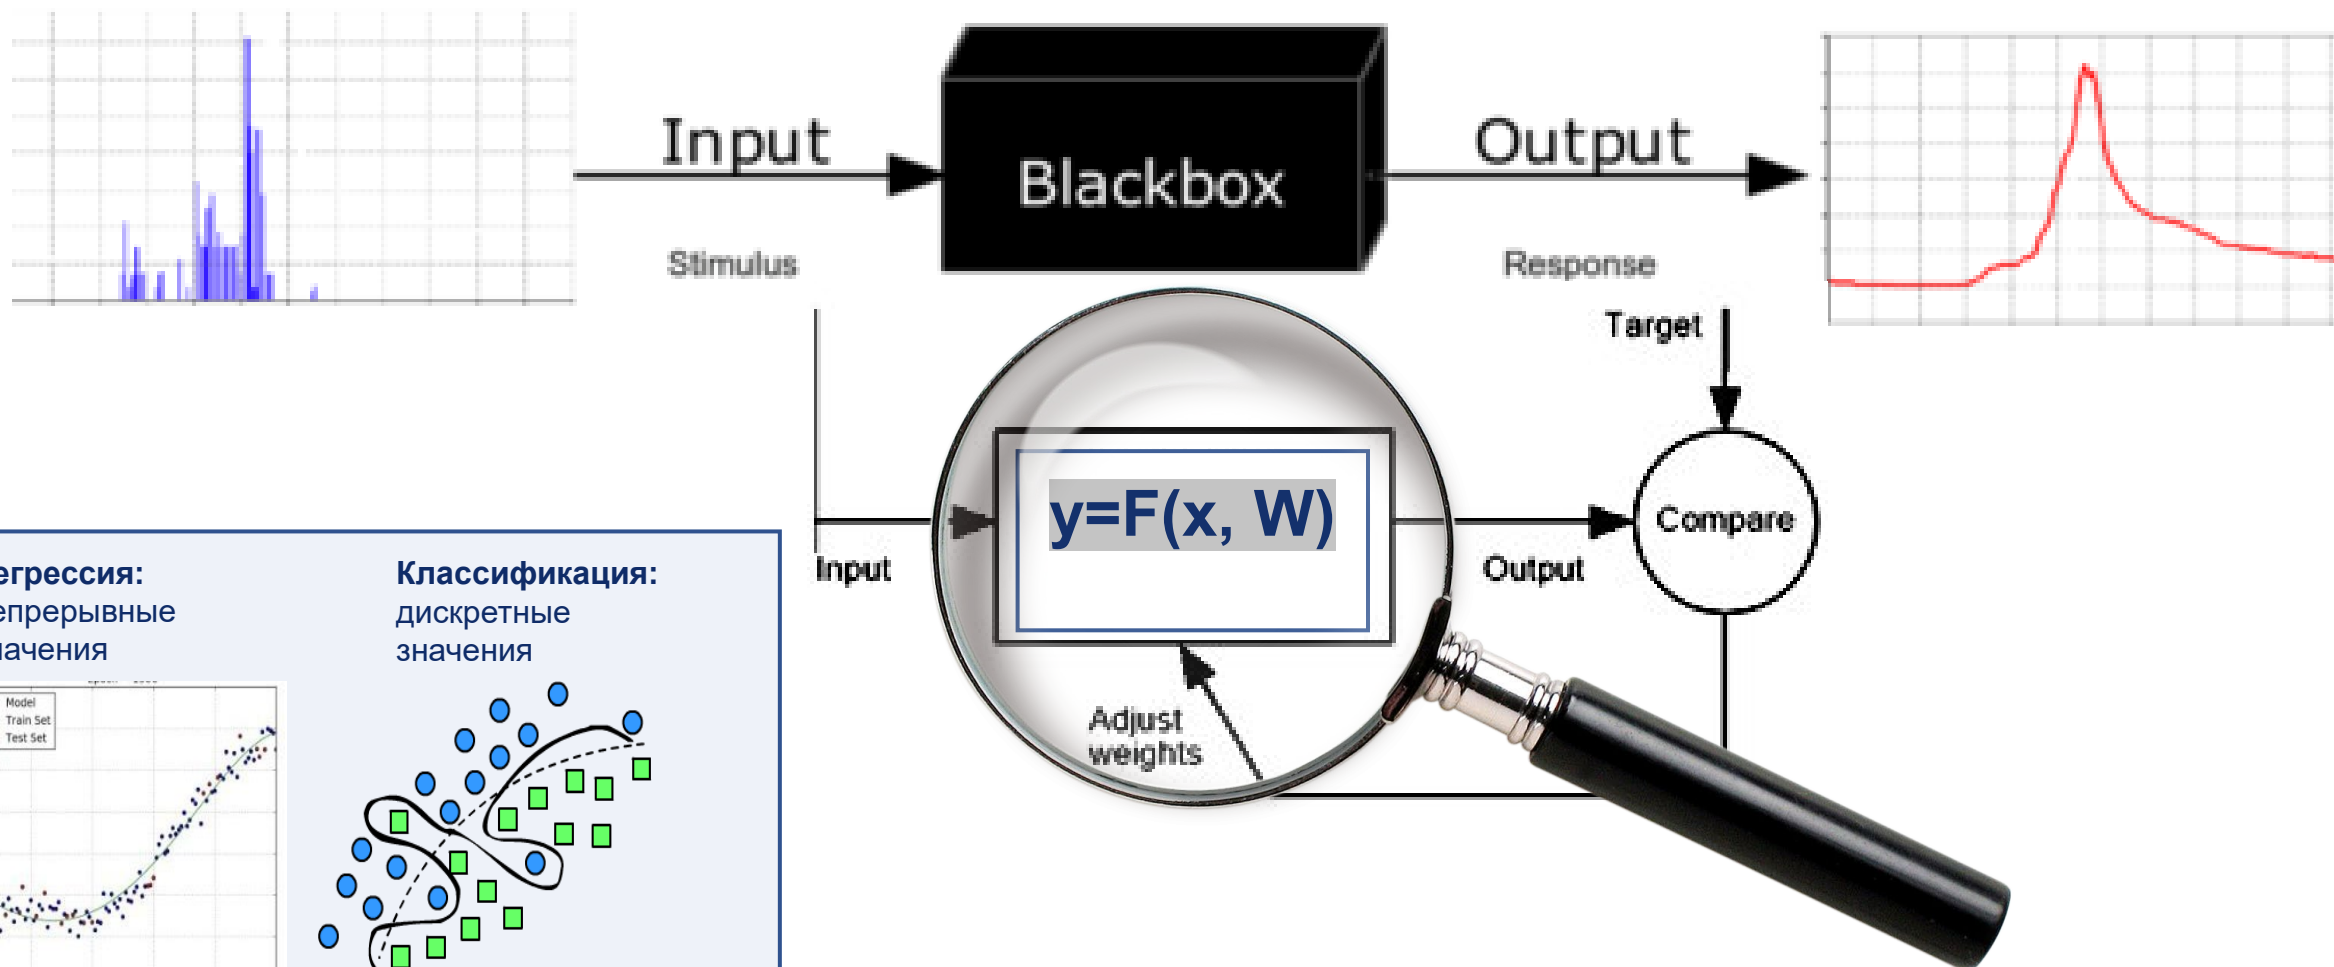
Линейные модели

- А. Линейная регрессия
- Б. Регуляризация, Ridge, Lasso и ElasticNet
- В. Логистическая регрессия, LogLoss
- Г. Машины опорных векторов




«Черный ящик»

2



Регрессия:
непрерывные
значения




Классификация:
дискретные
значения





Линейная регрессия

3



- движение тел по инерции
- экономические расчеты, ценообразование
- расчеты металлоконструкций, тепловое удлинение рельс
- ...

«Линейная» = линейная по параметрам

Simple
Linear
Regression

$$y = b_0 + b_1 x_1$$

Multiple
Linear
Regression

$$y = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_n x_n$$

Polynomial
Linear
Regression

$$y = b_0 + b_1 x_1 + b_2 x_1^2 + \dots + b_n x_1^n$$

$$y = a * x + b$$

$$\vec{y} = A * \vec{x} + \vec{b}$$

\vec{x} — вектор размерности N

\vec{y} — вектор размерности M

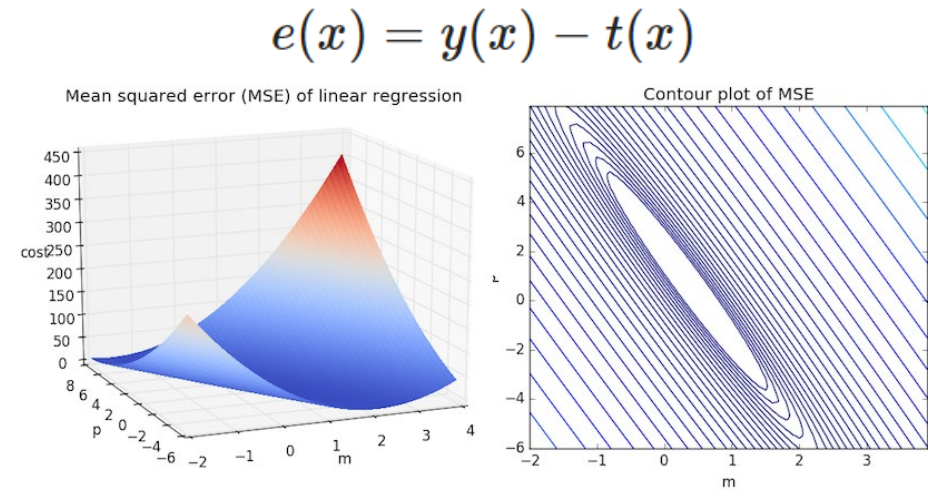

\vec{b} — вектор размерности M

A — матрица размерности $M * N$



Линейная регрессия. Расчет ошибки

4



$$E = \sum_{i=1}^P e(x_i)^2 = \sum_{i=1}^P (y(x_i) - t(x_i))^2$$

x_i : i — ый пример входа

$t(x_i)$: указание учителя для него

$y(x_i)$: выход модели для него




Линейная регрессия. Обучение

5

Не итерационный МНК

Итерационный МНК
Градиентный спуск

$$\begin{cases} a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i \\ na + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \end{cases}.$$



$$E = \sum_{i=1}^P e(x_i)^2 = \sum_{i=1}^P (y(x_i) - t(x_i))^2$$

for $n = 1 : N$



$$\theta = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

$$w_i^n := w_i^{n-1} - \eta \frac{\partial E_n(\mathbf{w})}{\partial w_i}$$



Линейная регрессия для классификации

6





Accuracy = 0.94



Линейная регрессия. Проблемы

7


- Восстанавливает только линейные зависимости
- Не очень удобна для классификации
- Чувствительна к выбросам!





Регуляризация

8



$$L = L_{\text{задача}} + \alpha * L_{\text{регуляризация}}$$

$$L_1 = \sum_i |W_i|$$


$$L_2 = \sum_i W_i^2$$





Логистическая регрессия. Задача классификации

9


Binary classification:



Multi-class classification:



One-hot encoding





Логистическая регрессия. Уровень уверенности

10

Выход 0.7 – Цель
1

Выход 0.9 -

Цель 1

Выход 0.3 – Цель

0

Выход 0.4 – Цель
0

Выход 0.5 – ??

Выход 0.7 – Цель
0

Выход 0.9 -

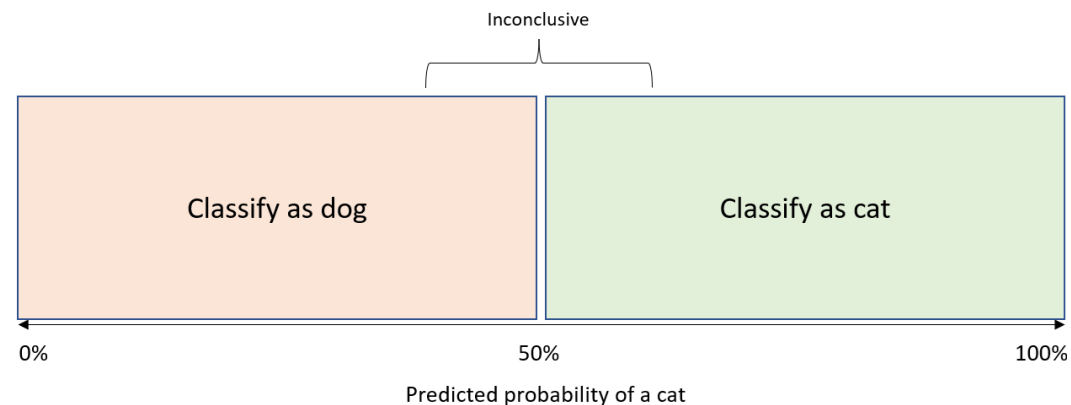
Цель 0

Выход 0.3 – Цель

1

Выход 0.4 – Цель
1


Выход 0.5 – ??





Логистическая регрессия. Модель

11






Логистическая регрессия. Сигмоида

12

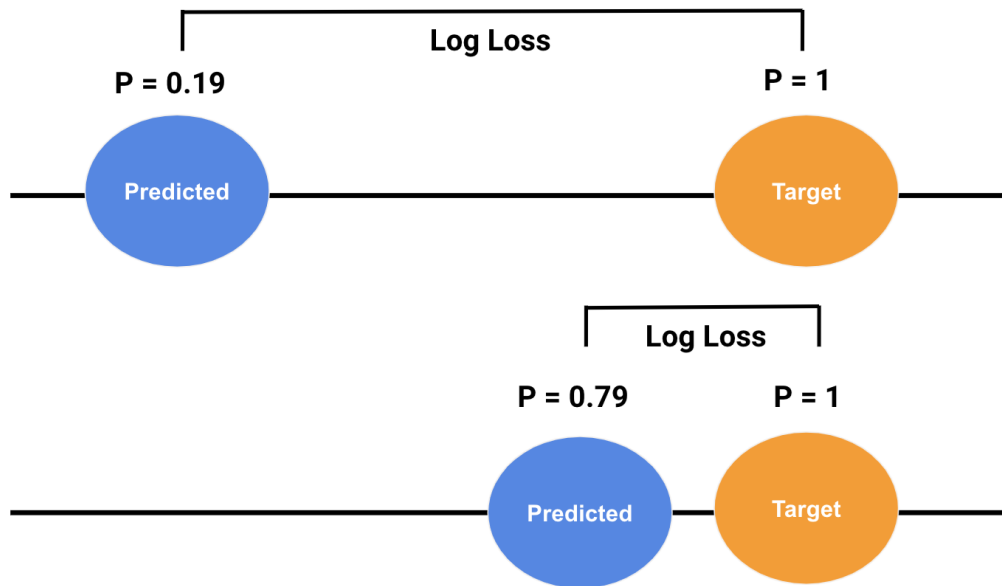
- Logit: $\ln[p/(1-p)] = a + BX$
- Logistic: $p = \frac{e^{a+BX}}{1+e^{a+BX}}$





Логистическая регрессия. Ошибка классификации LogLoss

13



Один пример:

Выход Y | Цель $t=1$? уверенность $E=Y$

Выход Y | Цель $t=0$? уверенность $E=1-Y$

Совместим: $E=(1-Y)*(1-t)+t*Y$



Логистическая регрессия. Ошибка классификации LogLoss

14

Много примеров:

0	1	1
0.1	0.9	0.8



$$(1-0.1) * 0.9 * 0.8 = 0.648$$

0	1	1
0.4	0.6	0.5



$$(1-0.4) * 0.6 * 0.5 = 0.18$$

0	1	1
0.7	0.2	0.1



$$(1-0.7) * 0.2 * 0.1 = 0.006$$

0	1	1
0.2	0.7	0.2



$$(1-0.2) * 0.7 * 0.2 = 0.112$$

- Простая сумма не подойдет
- Произведение уверенностей!
- Произведение сложно считать ?
сумма логарифмов (со знаком минус)

$$E = \sum_{i=1}^P (t(x_i) * \ln(y(x_i)) + (1 - t(x_i)) * \ln(1 - y(x_i)))$$

x_i : i — ый пример входа

$t(x_i)$: указание учителя для него

$y(x_i)$: выход модели для него



Логистическая регрессия. Реализация sklearn


15

sklearn.linear_model.LogisticRegression

```
class sklearn.linear_model.LogisticRegression(penalty='l2', *, dual=False, tol=0.0001, C=1.0, fit_intercept=True, intercept_scaling=1, class_weight=None, random_state=None, solver='lbfgs', max_iter=100, multi_class='auto', verbose=0, warm_start=False, n_jobs=None, l1_ratio=None)
```

$L+1/C * \text{reg}$

[\[source\]](#)






Логистическая регрессия. Разделяющая поверхность


16

Decision boundary



(a)



Decision boundary




(b)

https://www.researchgate.net/figure/Example-of-overfitting-in-classification-a-Decision-boundary-that-best-fits-training_fig1_349186066

Линейная регрессия $y=0$




Логистическая регрессия $y=0.5$






Машины опорных векторов

17



$$\begin{cases} (w^T w)/2 \rightarrow \min \\ y(w^T x - b) \geq 1 \quad | M = y(w^T x - b) \end{cases}$$




$$Q = \max(0, 1 - M_i) + \alpha(w^T w)/2$$




Машины опорных векторов

18



Data Transformed with SVM



$$y(x) = w^T \phi(x) + b$$

Common kernel functions for SVM

— linear

$$k(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1 \cdot \mathbf{x}_2$$

— polynomial

$$k(\mathbf{x}_1, \mathbf{x}_2) = (\gamma \mathbf{x}_1 \cdot \mathbf{x}_2 + c)^d$$

— Gaussian or radial basis

$$k(\mathbf{x}_1, \mathbf{x}_2) = \exp(-\gamma \|\mathbf{x}_1 - \mathbf{x}_2\|^2)$$

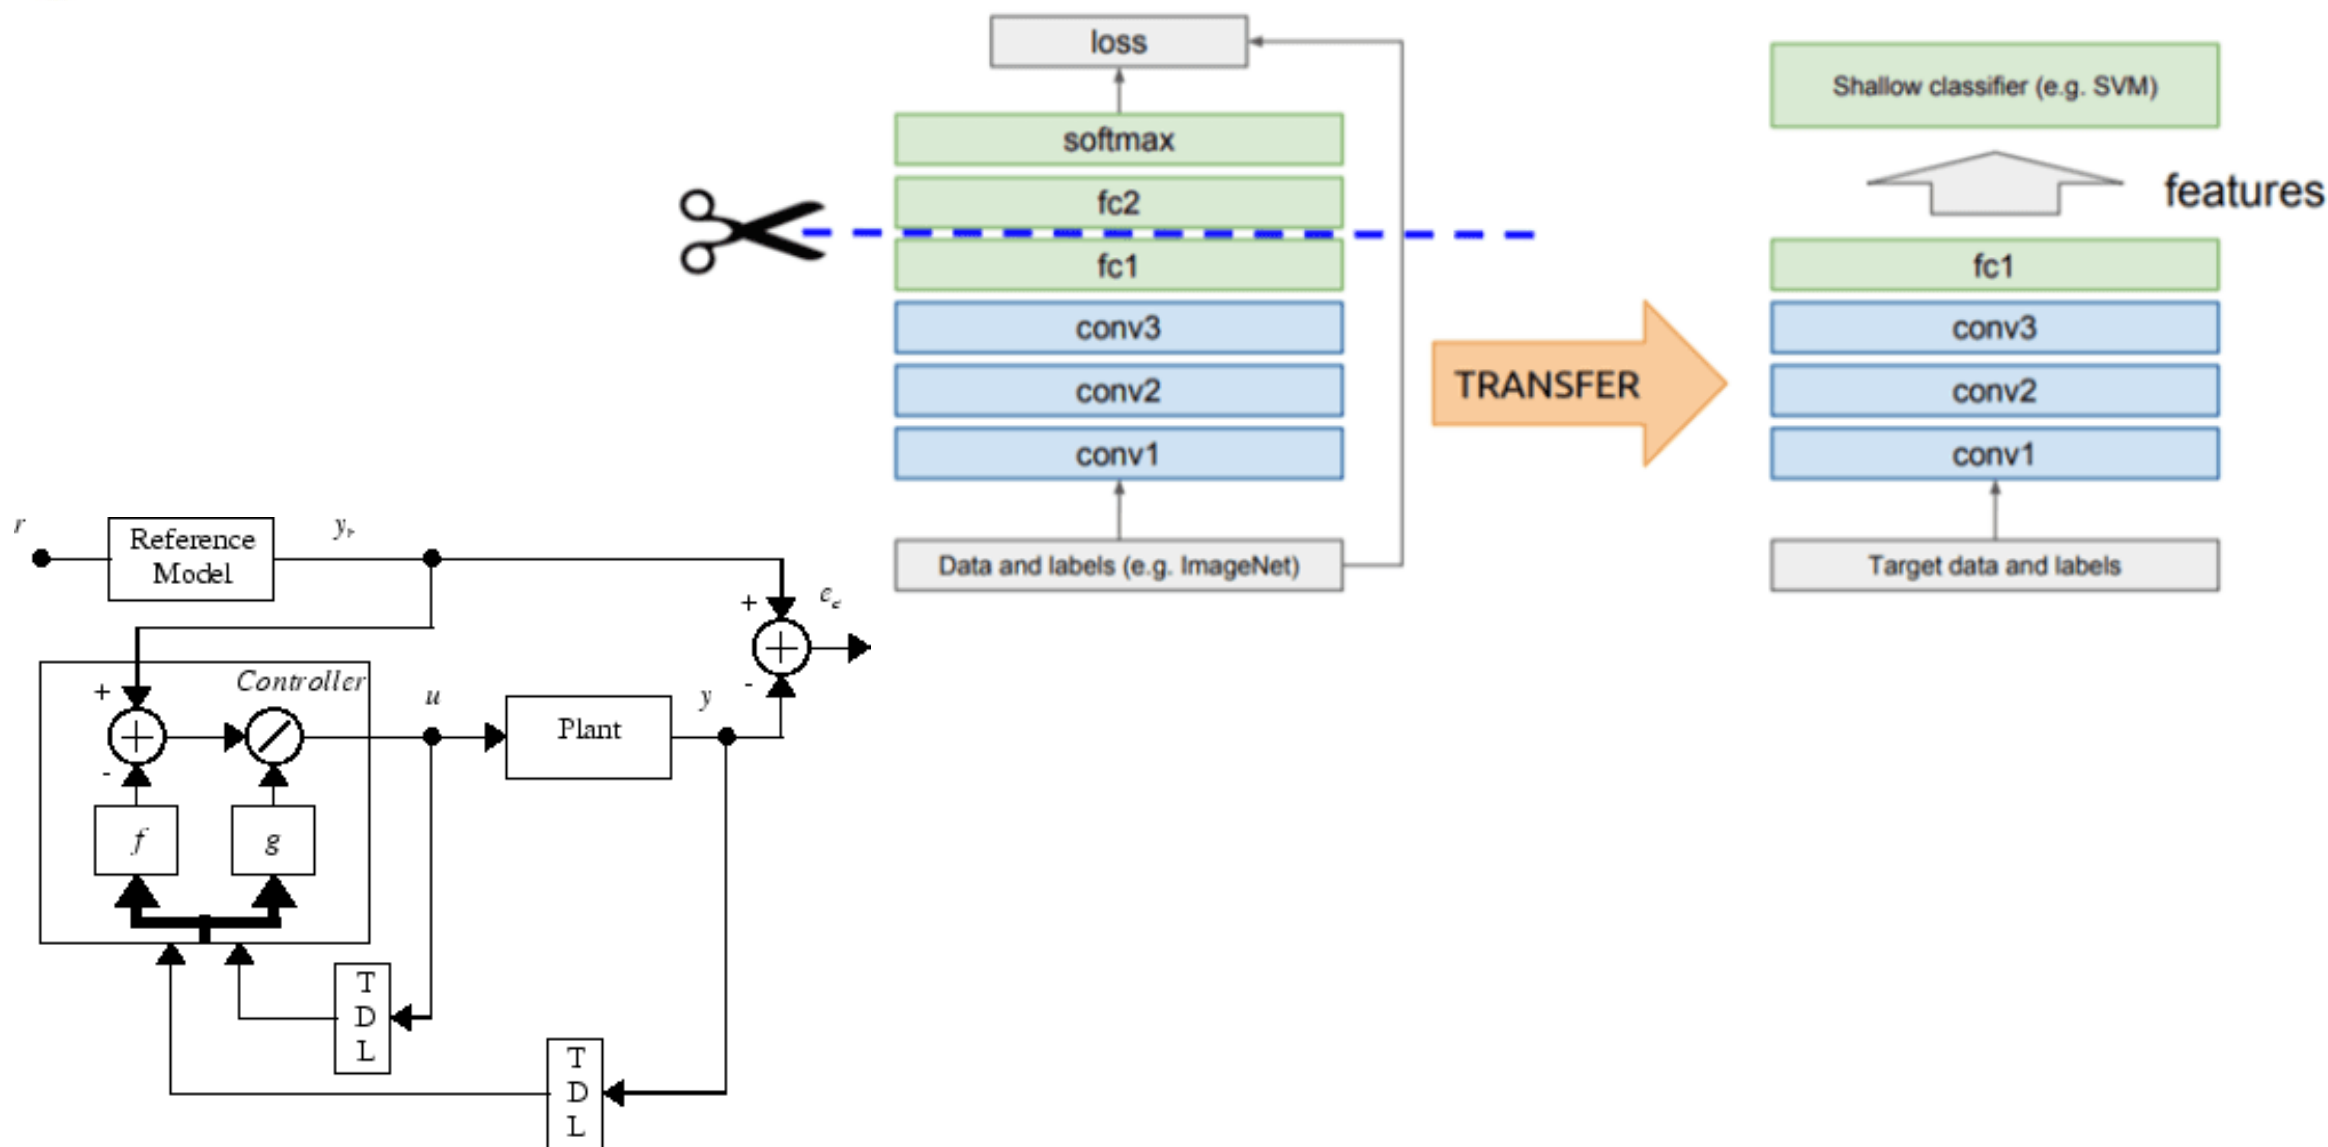
— sigmoid

$$k(\mathbf{x}_1, \mathbf{x}_2) = \tanh(\gamma \mathbf{x}_1 \cdot \mathbf{x}_2 + c)$$



Линеаризация и перенос обучения

19





Группа по дисциплине:

<https://t.me/+8dShF1tFSDg0ZmJi>

