



# Лекция 04

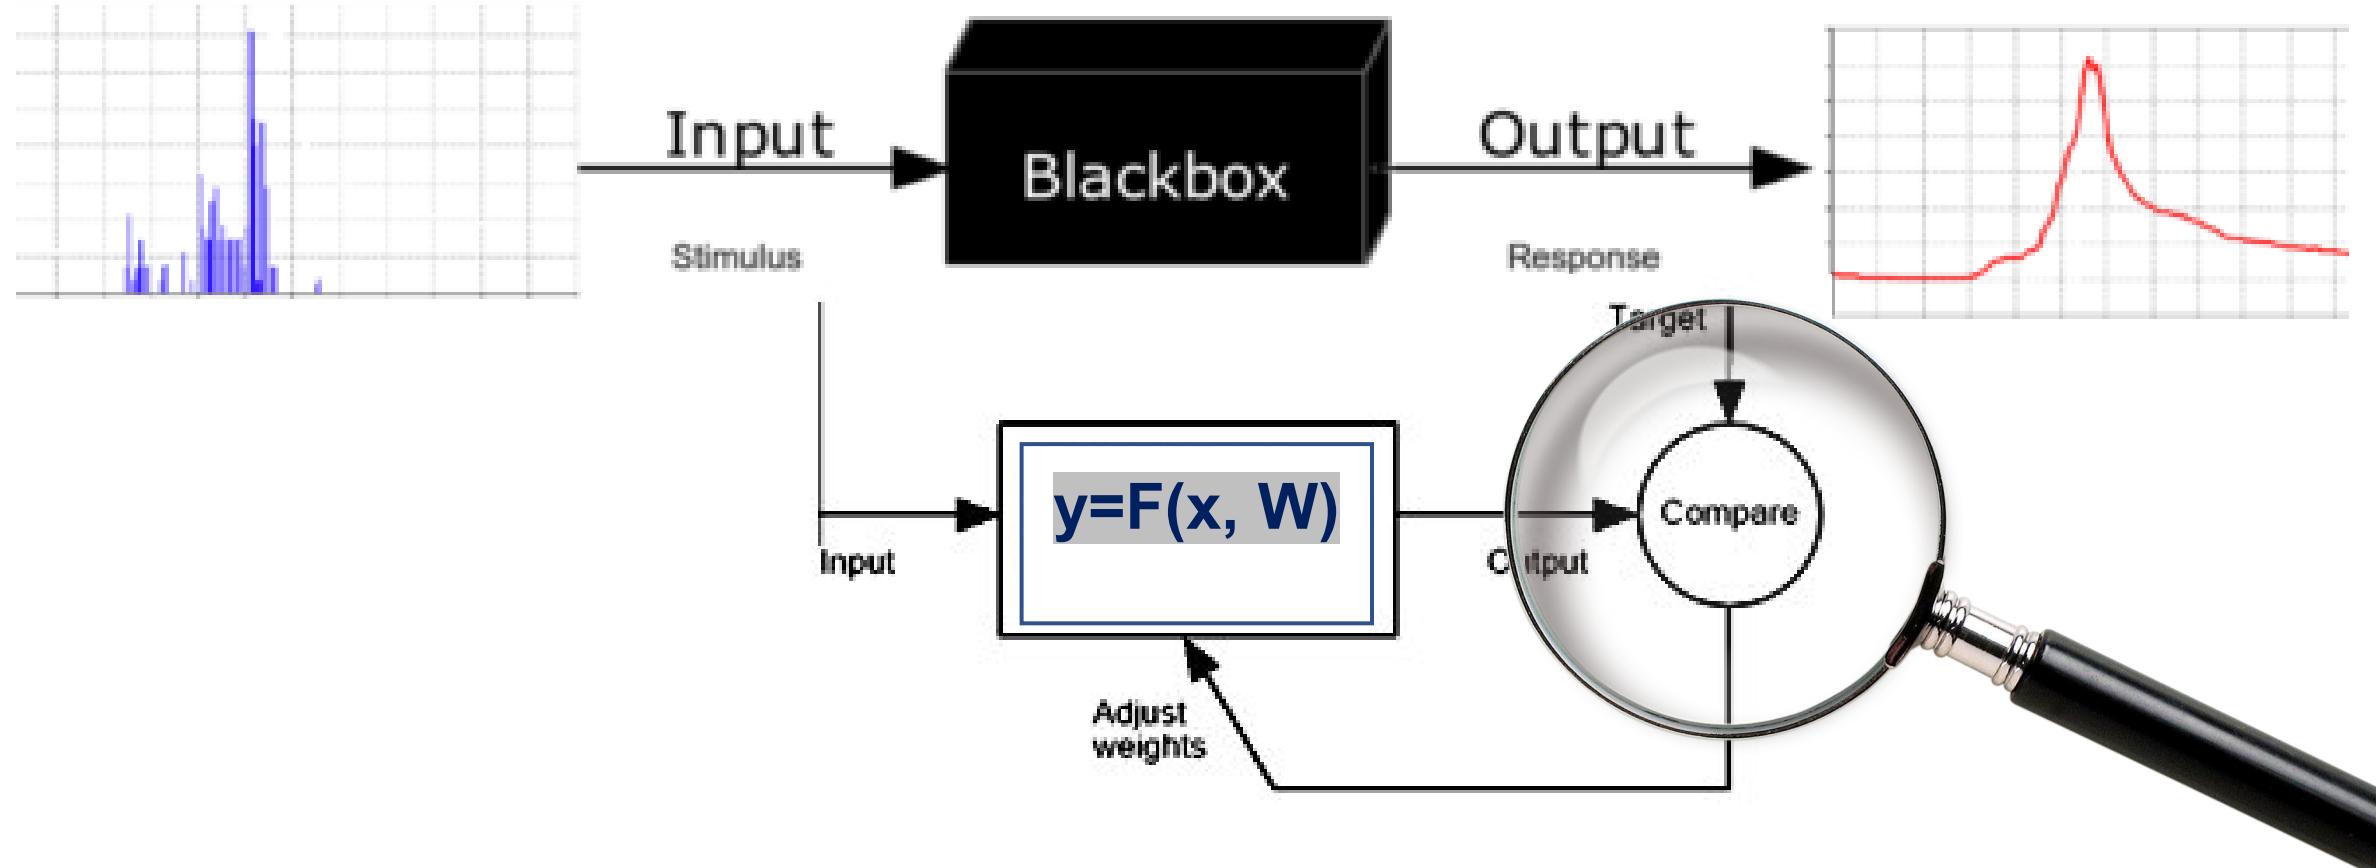
## Метрики и экспериментальный дизайн

- А. Задачи
- Б. Метрики регрессии
- В. Метрики классификации
- Г. Метрики кластеризации
- Д. Метрики производительности



## «Черный ящик»

2

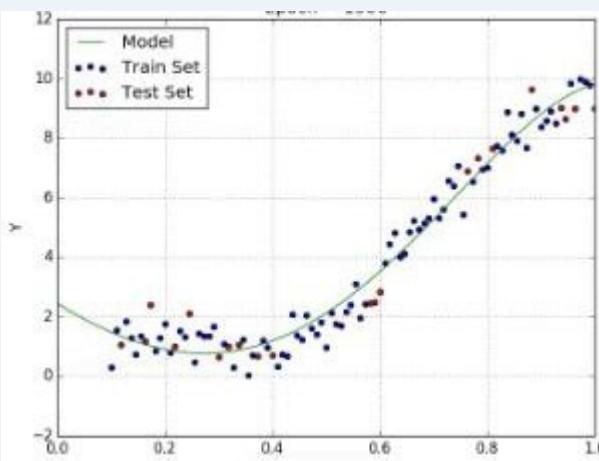




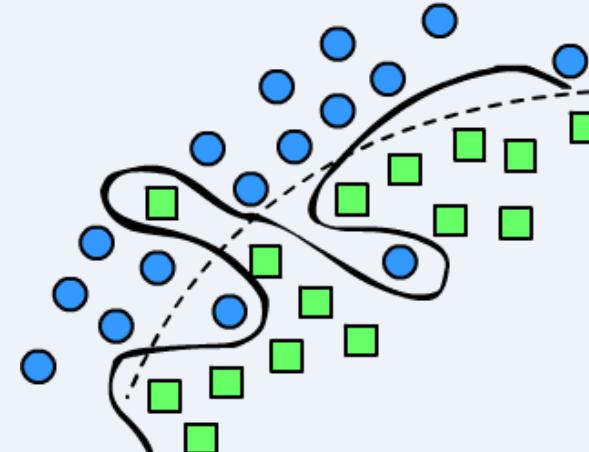
# Задачи

3

## Регрессия: непрерывные значения



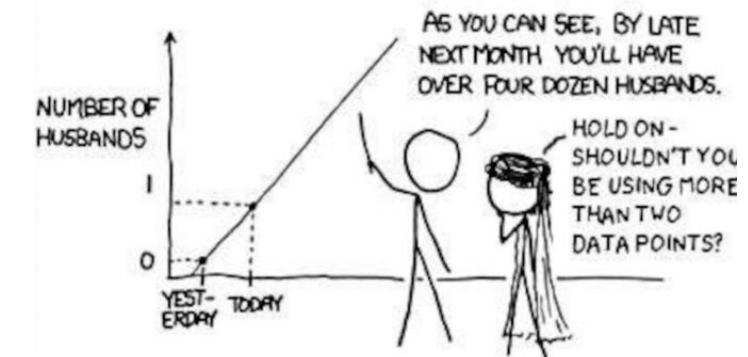
## Классификация: дискретные значения



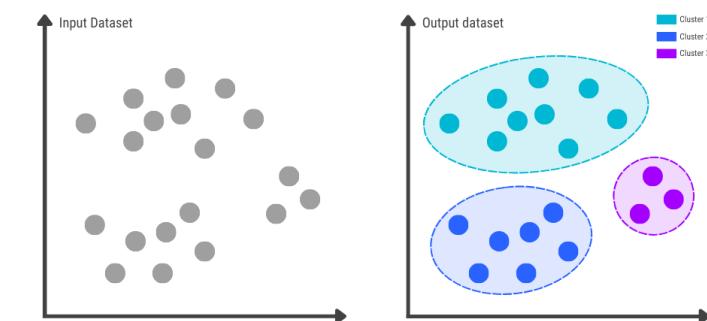
На одном – мгновенная  
На наборе – усредненная  
На последовательности - временная

	true relevance	predicted relevance
	1	0.7
	0	0.5
	0	0.5
	0	0.5

## Прогнозирование: будущие значения



## Кластеризация: близость значений

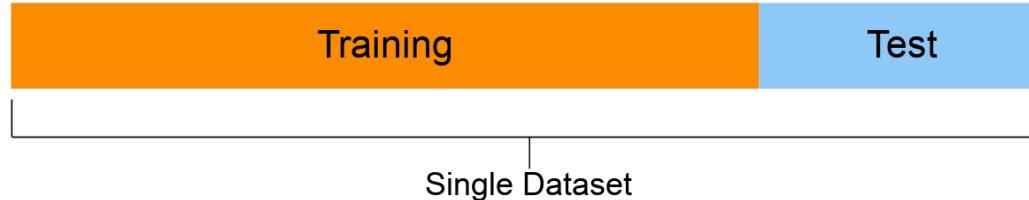




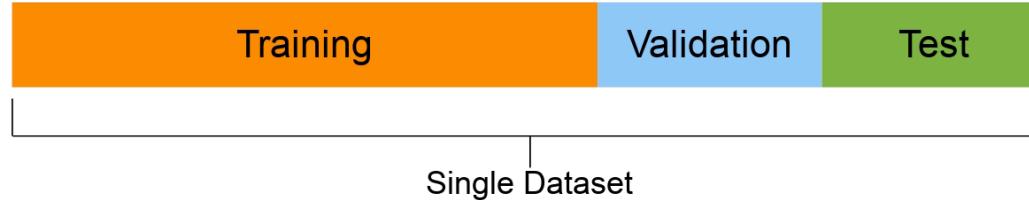
# Обучение VS тест. Метрики VS Функции ошибки

4

A



B



**Функция ошибки Loss – чему учим**



**Метрика metric – что наблюдаем**

**Метрики:**

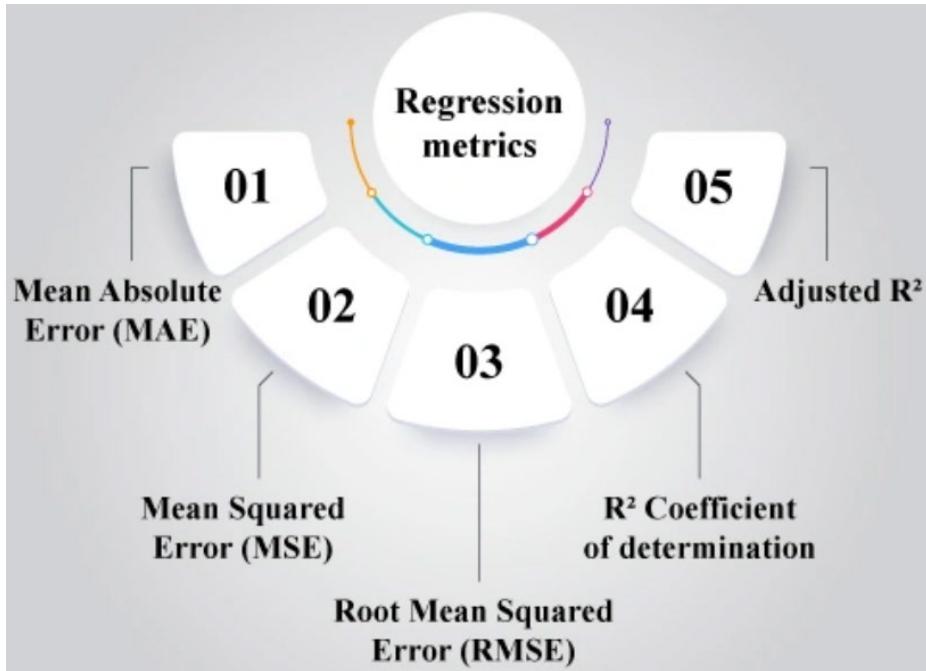
Прикладные – что действительно хотим



Математические – что можем посчитать сейчас



# Метрики регрессии



$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2}$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

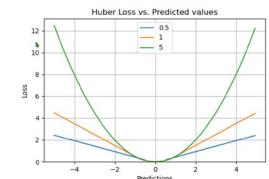
$$\text{MBE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)$$

$$\text{RAE} = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i - \bar{y}|}$$

where  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  Normalized ....

Huber Loss

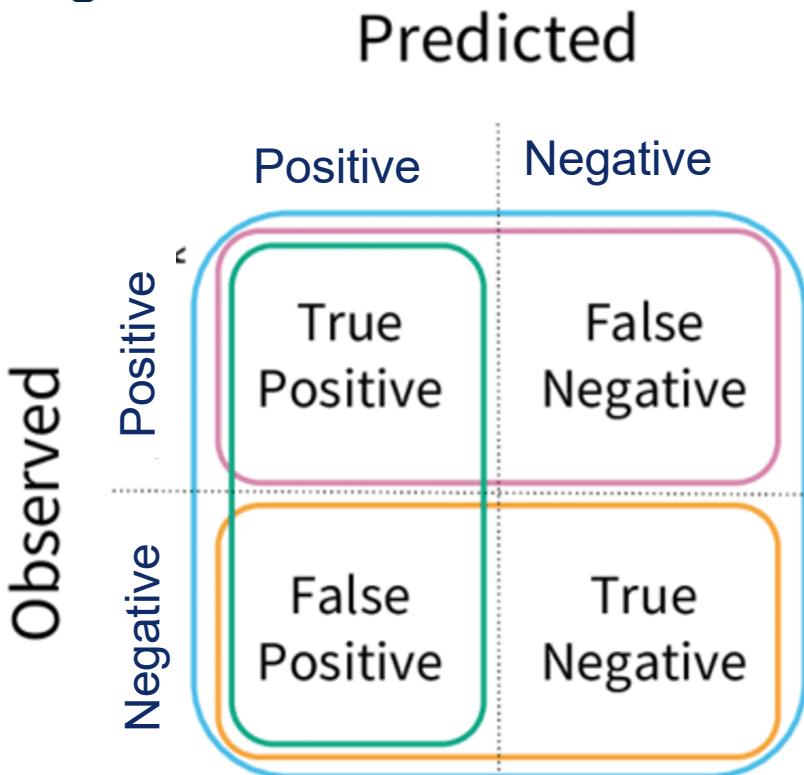
$$L_\delta(y, f(x)) = \begin{cases} \frac{1}{2}(y - f(x))^2 & \text{for } |y - f(x)| \leq \delta, \\ \delta |y - f(x)| - \frac{1}{2}\delta^2 & \text{otherwise.} \end{cases}$$





## Метрики классификации. Бинарная

6



Accuracy =  $\frac{TP + TN}{TP + TN + FP + FN}$

Specificity =  $\frac{TN}{TN + FP}$

Precision =  $\frac{TP}{TP + FP}$

Recall =  $\frac{TP}{TP + FN}$

$$F\beta \text{ Score} = \frac{(1 + \beta^2) \times \text{Precision} \times \text{Recall}}{(\beta^2 \times \text{Precision}) + \text{Recall}}$$



## Метрики классификации. AUC

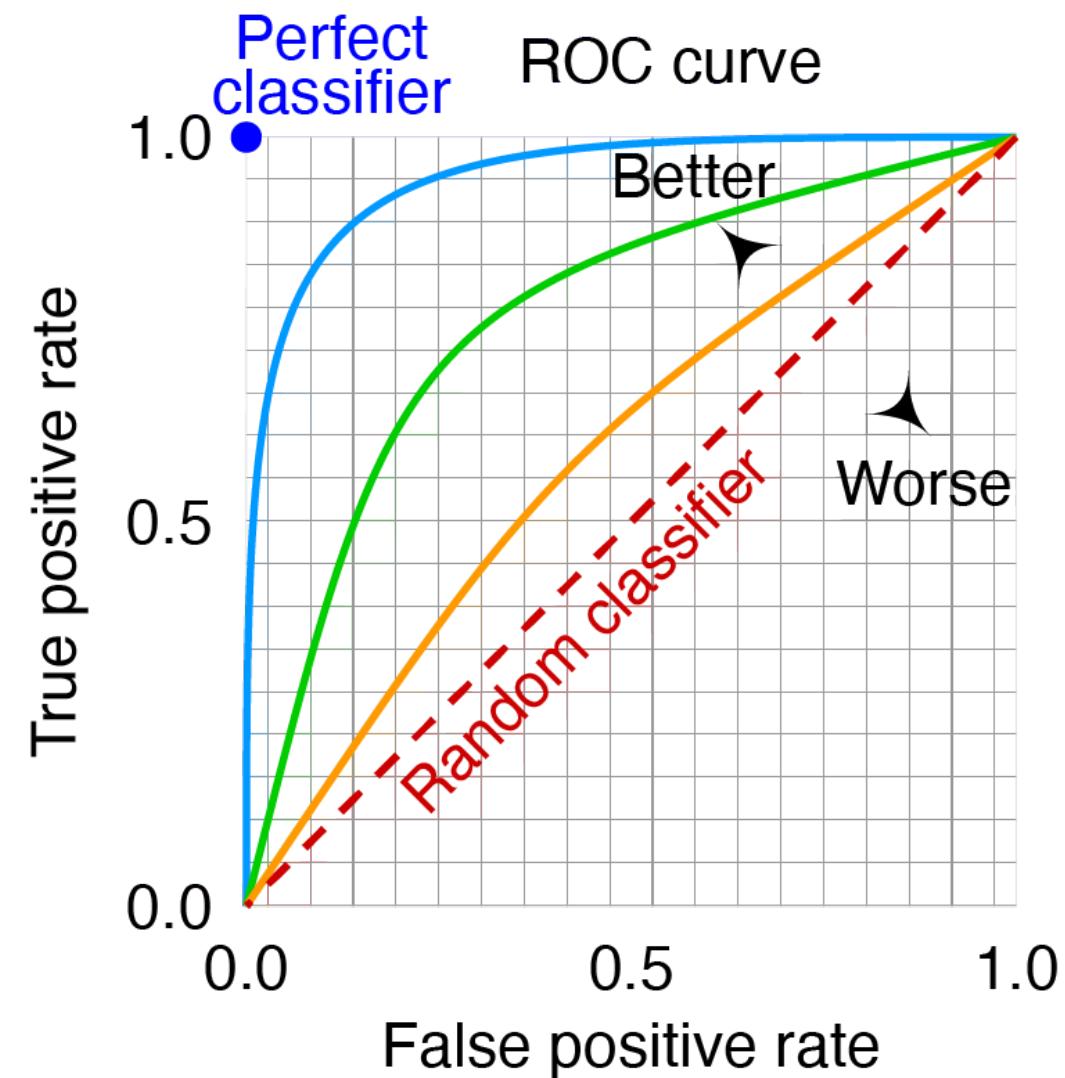
7

Color

	Red	Yellow	Green
Red	1	0	0
Red	1	0	0
Yellow	0	1	0
Green	0	0	1
Yellow	0	1	0

LogLoss

$$-\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$



<https://towardsdatascience.com/understanding-auc-scores-in-depth-whats-the-point-5f2505eb499f/>



# Метрики классификации. Многоклассовая

8

	precision	recall	f1-score	support
Aeroplane	0.67	0.67	0.67	3
Boat	0.25	1.00	0.40	1
Car	1.00	0.50	0.67	6
accuracy				10
macro avg	0.64	0.72	0.58	10
weighted avg	0.82	0.60	0.64	10

Average F1 scores

## One-vs-Rest (OvR)

Label	True Positive (TP)	False Positive (FP)	False Negative (FN)	Precision	Recall	F1 Score
Airplane	2	1	1	0.67	0.67	$2 * (0.67 * 0.67) / (0.67 + 0.67) = 0.67$
Boat	1	3	0	0.25	1.00	$2 * (0.25 * 1.00) / (0.25 + 1.00) = 0.40$
Car	3	0	3	1.00	0.50	$2 * (1.00 * 0.50) / (1.00 + 0.50) = 0.67$

Predicted			
Actual	Airplane	Boat	Car
Airplane	2	1	0
Boat	0	1	0
Car	1	2	3

Label	Per-Class F1 Score	Macro-Averaged F1 Score
Airplane	0.67	
Boat	0.40	
Car	0.67	$\frac{0.67 + 0.40 + 0.67}{3} = 0.58$

Label	Per-Class F1 Score	Support	Support Proportion	Weighted Average F1 Score
Airplane	0.67	3	0.3	
Boat	0.40	1	0.1	
Car	0.67	6	0.6	
Total	-	10	1.0	$(0.67 * 0.3) + (0.40 * 0.1) + (0.67 * 0.6) = 0.64$

Label	True Positive (TP)	False Positive (FP)	False Negative (FN)	Micro-Averaged F1 Score
Airplane	2	1	1	
Boat	1	3	0	
Car	3	0	3	
TOTAL	6	4	4	$\frac{TP}{TP + \frac{1}{2}(FP+FN)} = \frac{6}{6 + \frac{1}{2}(4+4)} = 0.60$

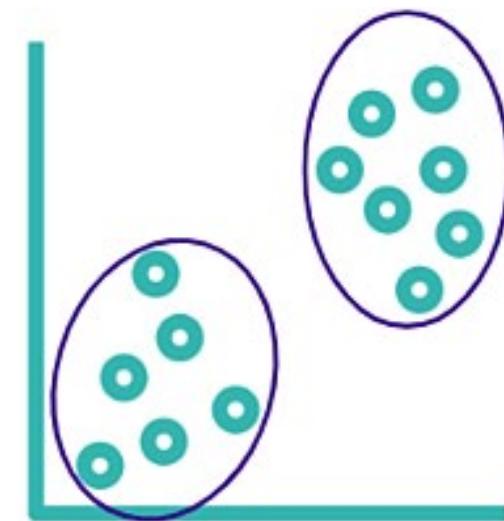
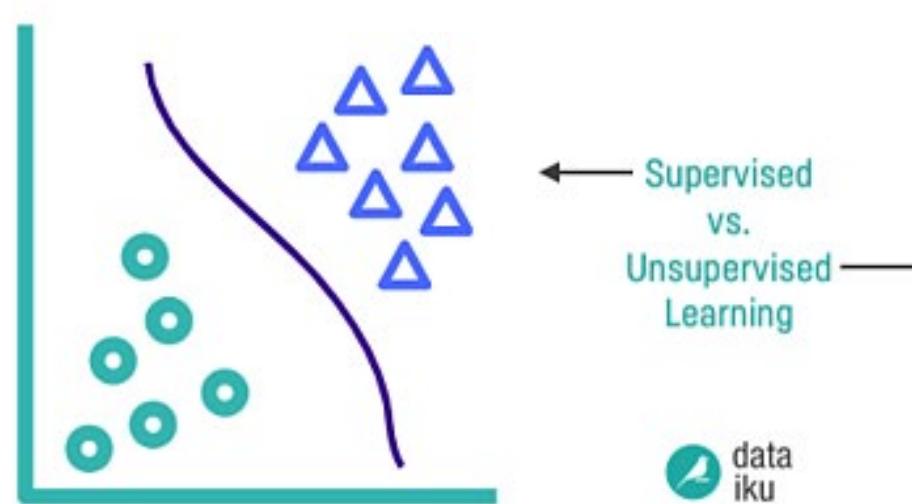
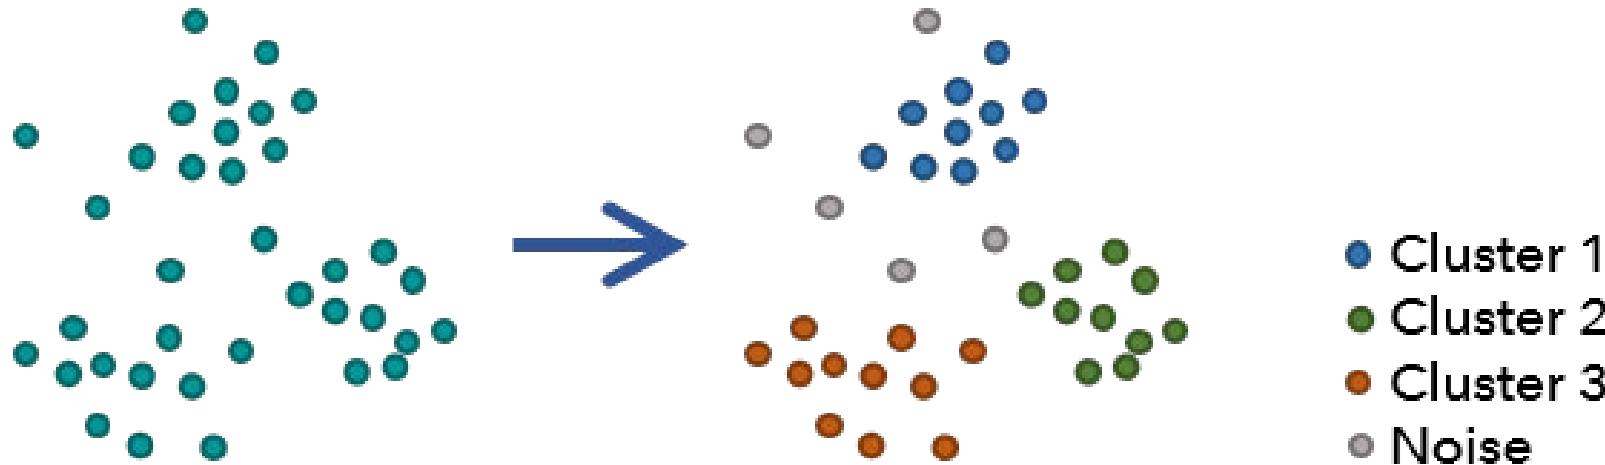
$$F1 \text{ Score} = \frac{TP}{TP + \frac{1}{2}(FP+FN)}$$

Не надо спрашивать «Какая лучше?». Публикуйте все.



## Метрики кластеризации

9



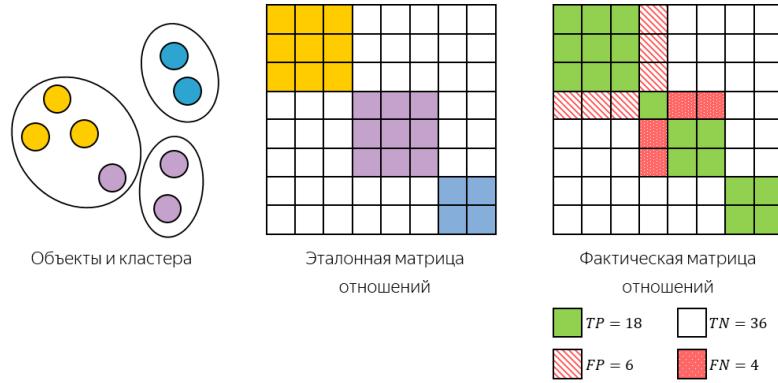


# Метрики кластеризации

10

## ВНЕШНИЕ

Есть эталонные кластеры (классы) (редкость!)



$$Rand = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Jaccard = \frac{TP}{TP + FN + FP}$$

$$\widehat{ARI} = \frac{\frac{\text{Index}}{\sum_{ij} \binom{n_{ij}}{2} - [\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}] / \binom{n}{2}} - \frac{\text{Expected Index}}{\frac{1}{2} [\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}] - [\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}] / \binom{n}{2}}}{\frac{\text{Max Index}}{\sum_{ij} \binom{n_{ij}}{2} - [\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}] / \binom{n}{2}} - \frac{\text{Expected Index}}{\frac{1}{2} [\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}] - [\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}] / \binom{n}{2}}}$$

$$E = - \sum_i p_i \left( \sum_j \frac{p_{ij}}{p_i} \log \left( \frac{p_{ij}}{p_i} \right) \right)$$

однородность

$X \setminus Y$	$Y_1$	$Y_2$	$\dots$	$Y_s$	Sums
$X_1$	$n_{11}$	$n_{12}$	$\dots$	$n_{1s}$	$a_1$
$X_2$	$n_{21}$	$n_{22}$	$\dots$	$n_{2s}$	$a_2$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
$X_r$	$n_{r1}$	$n_{r2}$	$\dots$	$n_{rs}$	$a_r$
Sums	$b_1$	$b_2$	$\dots$	$b_s$	$n$

Пусть  $p_{ij} = \frac{n_{ij}}{n}$ ,  $p_i = \frac{a_i}{n}$ ,  $p_j = \frac{b_j}{n}$ .

- Элементы принадлежат одному кластеру и одному классу —  $TP$
- Элементы принадлежат одному кластеру, но разным классам —  $FP$
- Элементы принадлежат разным кластерам, но одному классу —  $FN$
- Элементы принадлежат разным кластерам и разным классам —  $TN$

Пары примеров. Число перестановок:  $\binom{n}{k} = \frac{n!}{k!(n-k)!}$



# Метрики кластеризации

11

## Компактность

$$WSS = \sum_{j=1}^M \sum_{i=1}^{|C_j|} (x_{ij} - \bar{x}_j)^2$$

## Отделимость

$$BSS = n \cdot \sum_{j=1}^M (\bar{x}_j - \bar{x})^2$$

## Силуэт

a – среднее до точек внутри кластера

b – минимальное среднее до точек другого кластера

$$a(x_i, c_k) = \frac{1}{|c_k|} \sum_{x_j \in c_k} \|x_i - x_j\|$$

$$b(x_i, c_k) = \min_{c_l \in C \setminus c_k} \left\{ \frac{1}{|c_l|} \sum_{x_j \in c_l} \|x_i - x_j\| \right\}$$

$$Sil(C) = \frac{1}{N} \sum_{c_k \in C} \sum_{x_i \in c_k} \frac{b(x_i, c_k) - a(x_i, c_k)}{\max\{a(x_i, c_k), b(x_i, c_k)\}},$$

<https://habr.com/ru/company/yandex/blog/500742/>

## ВНУТРЕННИЕ

Нет эталонных кластеров.

Сравниваем кластеры между собой и их центроиды

Kullback Leibler  
Divergence Loss

$$\mathcal{L}_{KL}(x_m, x_n) = \sum_{j=1}^C \mathbf{s}_m^j * \log \frac{\mathbf{s}_m^j}{\mathbf{s}_n^j}.$$

## Индекс Дэвиса-Болдуина

$$DB(C) = \frac{1}{K} \sum_{c_k \in C} \max_{c_l \in C \setminus c_k} \left\{ \frac{S(c_k) + S(c_l)}{\|\bar{c}_k - \bar{c}_l\|} \right\},$$

где:

$$S(c_k) = \frac{1}{|c_k|} \sum_{x_i \in c_k} \|x_i - \bar{c}_k\|$$

<https://www.geeksforgeeks.org/machine-learning/clustering-metrics/>



## Метрики производительности

12

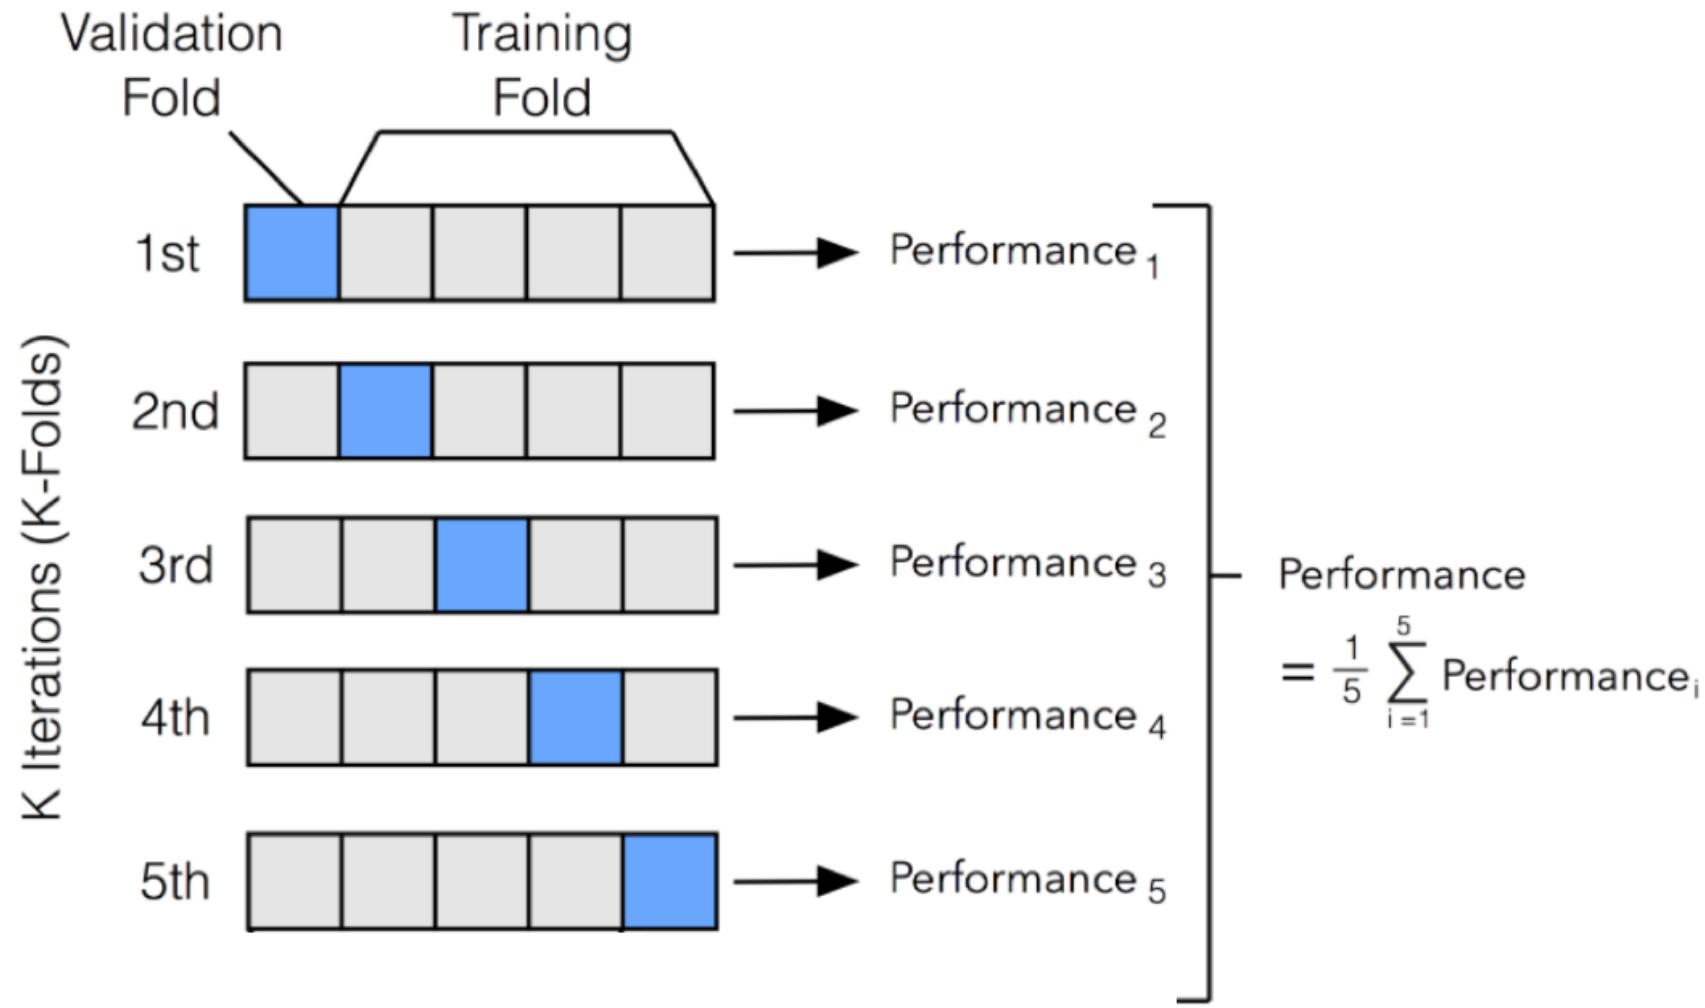
- Размер модели
- Размерность данных (входы, выходы, эмбединги и т.п.)
- Время обучения, частота переобучения и т.п.
- Время инференса (общее и латентность)
- Потребляемая память (по видам)
- ...

Хороший инженер протоколирует ВСЕ



## Кроссвалидация

13





Группа по дисциплине:

<https://t.me/+8dShF1tFSDg0ZmJi>

